北京航空航天大學 COLLEGE OF SOFTWARE BEIHANG UNIVERSITY 软件学院

专业硕士学位论文

文献综述

面向 AI Agent 安全的多级外挂式检测方法研究

作 者 姓 名　金祺昌

作 者 学 号　ZF2421105

专 业 名 称：软件工程

学院指导教师　胡峻林副教授

企业实习导师　邵菊产品技术总监

企业实习导师单位　三六零安全科技股份有限公司

培 养 学 院　软件学院

论文起止时间　2025 年 9 月 ~ 2025 年 12 月

文献综述提交时间　2025 年 12 月

摘　要

随着大语言模型（Large Language Models, LLMs）在技术能力上的飞速迭代与应用场景的全面渗透，其生成内容的安全性已受到学术界与工业界的广泛关注，成为其合规、可信、安全落地的重要议题。本文在研究了国内外当前的主流技术、方法及解决方案后，围绕大模型内容安全防护领域展开系统性文献梳理。首先，概括性描述了近年国内外相关研究的整体安全态势；其次，分别从安全对齐技术、外部防御与过滤系统、红队测试与安全评估、隐私保护机制、特定攻击防御共五大分支展开研究，分析其当前现状与主要技术方法，系统剖析各分支的理论支撑和方案，如直接偏好优化（Direct Preference Optimization, DPO）、多层防御框架、可验证安全机制等；随后，总结了在大模型安全领域中，当前已有的成果，并阐明当前的方法也存在一定的不如，如安全与效用难以平衡、对抗攻击的鲁棒性仍待提升、评估标准统一化落地等关键难点。研究表明，未来大模型内容安全防护将朝着可证明式安全、轻量高效、自动化及标准化的方向演进。本文通过构建清晰的脉络展示当前研究现状并表明未来的发展方向，为相关领域的研究和产业落地实践提供参考。

关键词： 大语言模型；内容安全；安全对齐；对抗性防御；红队测试；隐私保护

Abstract

With the rapid iteration of technical capabilities and comprehensive penetration of application scenarios of Large Language Models (LLMs), the safety of their generated content has attracted widespread attention from both academia and industry, becoming a crucial issue for their compliant, trustworthy, and secure implementation. After investigating the current mainstream technologies, methods, and solutions at home and abroad, this paper conducts a systematic literature review focusing on the field of LLM content safety protection. Firstly, it provides a general description of the overall safety landscape of relevant research worldwide in recent years. Secondly, it conducts in-depth research from five core branches—safety alignment techniques, external defense and filtering systems, red teaming and safety evaluation, privacy protection mechanisms, and defenses against specific attacks—analyzing their current status and main technical approaches, as well as systematically dissecting the theoretical support and solutions of each branch (such as Direct Preference Optimization (DPO), multi-layer defense frameworks, verifiable security mechanisms, etc.). Subsequently, it summarizes the existing achievements in the field of LLM safety and clarifies the inherent limitations of current methods, including key challenges such as the difficulty in balancing safety and utility, the need to improve robustness against adversarial attacks, and the implementation of unified evaluation standards. Research indicates that the future development of LLM content safety protection will evolve towards provable safety, lightweight efficiency, automation, and standardization. By constructing a clear framework to present the current research status and future development directions, this paper provides valuable references for research in related fields and industrial implementation practices.

Keywords: Large Language Models; Content Safety; Safety Alignment; Adversarial Defense; Red Teaming; Privacy Protection

目　录

1 阅读文献概述 5
2 课题研究方向的研究现状与发展趋势 6
2.1 研究方向的若干分支 6
2.2 每个分支的理论/方法/方案/技术研究现状 7
2.3 关键问题已解决的程度与尚待解决的难点 12
2.4 未来发展的趋势 13
3 结论 14
参考文献 14

1 阅读文献概述

从 22 年 OpenAI 发布 GPT-3.5，2 个月用户破亿，彻底的将大模型推向大众视野，2023 的 GPT-4 与谷歌 Gemini 开启图文混合输入，大模型在复杂场景的理解又迎来提升，24 年 DeepSeek 的发布，7 天用户量破亿则更是将大模型推向高潮。而近年来具身智能、世界模型、人工智能（Artificial Intelligence, AI）原生操作系统的发布则更是将代表大模型在推动生产力的提升层面贡献巨大的作用。

然而，随着大模型的发展，其暴露出的安全问题也层出不穷。国际组织欧盟作为 AI 监管的先行者，在 24 年 7 月正式颁布《人工智能法》[1]，并在第 5 章节专门构建“通用目的人工智能模型”风险规制方案。而我国也近年来也发布了一系列的政策法规，对于大模型的安全进行约束。如《生成式人工智能服务暂行办法》[2]就明确将大模型的内容安全风险归结为 5 大类 31 小类的风险。在系统性精读近年三年内的国内外文献后，无论是国内还是国外，对于大模型发展过程中产生的安全性问题都相对关注。大模型在发展过程中面临很多的挑战，其中就包括大模型在内容生成过程中属于黑箱决策，具备不可解释性；大模型生成的内容存在伪造、有害、幻觉的问题；人工智能对人工智能（AI to AI, A2A）、多智能体通信协议（Multi-Agent Communication Protocol, MCP）、多智能体（Multi Agent）的发展，多系统交互放大了数据安全和系统安全风险；信息技术（Information Technology, IT）架构、智能体（Agent）架构改变了传统信息技术（Information Technology, IT）安全防护手段，催生风险传到。

针对大模型存在安全性的问题，Hubinger E、李卓君等人提出了多种的解决方案，包括如果通过训练和微调实现人类价值观的安全对其[3-6]；如何构建外部安全护栏与多级过滤体系拦截恶意输入输出[7,8]；如何通过红队测试与白盒测试主动发现模型漏洞[9,10]，通过内容安全评测数据集确保大模型输出安全；如何提升模型能力的同时防范隐私泄露风险[11,12]，确保大模型输出内容符合业务逻辑且不会存在过多恶意输出；如何针对提示词注入、越狱攻击等相对具体的攻击手法设计专项解决方案[13-15]。这些文献从不同的维度揭示了当前大模型内容安全防护是一个多层次、多技术的综合性课题，从早期的规则过滤、经验性对其，演进到基于机器学习双向编码器表示转换器（Bidirectional Encoder Representations from Transformers, BERT）分类[8]，再到通过模型的方式来防护模型这样的防护方式，大模型内容安全的防护正朝着更加科学、可验证、自动化的方向进行发展。从技术创新的维度来看，当前大模型安全防护已经进入了通过 AI 来对抗 AI 的阶段，涌

现出多项有突破性的技术成果。

尽管如此，大模型的安全性问题仍然面临着诸多的挑战，安全与业务的平衡、隐私与效能的优化仍然是当下较为关注的热点。

2 课题研究方向的研究现状与发展趋势

大语言模型的内容安全防护已形成一个综合性、多维度、多分支的技术体系，通过对现有文献的综合分析，可以将其归纳为几个核心的分支，在每个分支中都有不同的学者在进行研究。本篇将着重介绍当前研究发展的现状，同时补充每个分支研究的技术手段和解决方案情况。此外，基于当前研究总结已解决的问题和待解决的问题，以方便后续进行选题研究。并在本文的最后，补充未来可能发展的趋势。

2.1 研究方向的若干分支

2.1.1 安全对齐技术

该方法着重聚焦于确保大模型自身的安全，从模型训练到推理确保其全流程安全，在训练阶段采用安全对其语料，人类反馈强化学习（Reinforcement Learning from Human Feedback, RLHF）等技术纠正模型偏差[4]，使模型在内在生成行为符合人类的价值观。这种方式是最根本但同时也是最复杂的防护路径。

2.1.2 外部防御与过滤系统

该方法是抵御外部恶意威胁、恶意攻击、不合规输入的前置防线，通过在模型外部构建独立的干预检测模块，对用户输入的提示词（prompt）和模型的输出进行实时的检测和过滤[8]。整个检测层面可以基于关键字过滤、机器学习分类器和小尺寸大模型等方式实现对恶意内容进行识别和检测。这种方式可以作为模型自身安全性的重要屏障，同时解耦业务和安全，可以确保模型更加专注于能力层面的训练。

2.1.3 红队测试与安全评估

该方法通过主动的、自动化的方式发现大模型的漏洞，通过组建专业红队和专业化的工具来模拟攻击者，采用多样化的攻击手法对模型进行全方位的攻防演练，提前发现常规测试难以发现的隐蔽漏洞，以此来评估模型的安全性及防御系统的抗压能力[10]。这

种方式与上述几个分支不同，通过攻击的方式来验证模型的安全性，从而辅助评判模型的安全性。

2.1.4 隐私保护机制

该方法聚焦于大模型运行时全流程的隐私安全，核心是防止训练过程中模型训练数据中的隐私数据敏感信息泄露、用户交互时的隐私外泄，以及数据共享过程中的信息泄露，其中主要涉及到的内容包含个人身份信息、医疗病例、商业机密等信息。这种方式主要聚焦于敏感信息层面的防护，研究数据加密和数据脱敏等相关技术。

2.1.5 针对特定攻击的防御

该方法主要聚焦于对提示词注入、越狱攻击[13,14]等手法进行防护，而这类的攻击手法是大模型安全领域最活跃的攻击类型，二者的本质都是通过操作输入逻辑或者利用模型的缺陷，突破模型预设的安全边界。前者侧重于恶意输入篡改模型执行逻辑，后者侧重于诱导模型进行不安全的输出，两类攻击相互交织，形成复合威胁。这种方式主要聚焦于研究具体的攻击手法，通过研究攻击来辅助进行安全性防护体系的搭建。

2.2 每个分支的理论/方法/方案/技术研究现状

2.2.1 安全对齐技术

安全对齐的目标是使大模型输出的内容符合人类的价值观，输出内容“向善、可信、合规、有益”。当前主流的方式除了人工反馈强化学习 RLHF 外，也在此基础上有个更加有效、更加可控的一些方向，摆脱强化学习 RLHF 这种强依赖于人工反馈的方法。

基于人工智能反馈的强化学习（Reinforcement Learning from AI Feedback, RLAIF）：基于人类反馈的强化学习 RLHF 是目前实现模型无害化的基础方式。Anthropic 的研究[3,16] 通过 RLHF 训练出“有帮助且无害”的助手，证明了该路径的有效性。然而，RLHF 依赖高质量的人类偏好数据，成本高昂且可能存在标注偏差。然而，这种方法依赖高质量的人类偏好数据，其成本过于高昂，并且可能存在训练误差。因而，Constitutional AI[3] 创新性地提出用一套宪法原则替代人工标注，通过 RLAIF 进行训练，在降低对人力依赖的同时，提高了对齐过程的透明度与可控性。

直接偏好优化（Direct Preference Optimization, DPO）[17]：与 RLHF 不同，DPO

算法将偏好学习转化为更稳定的监督损失函数，并进行微调。而近期的研究则进一步在此基础上融入安全约束，如 Liu 等人[18]提出的 C-DPO 方法，通过双重梯度下降，在 DPO 框架内显性的施加安全约束，从而实现了安全性和可用性的良好平衡。李卓君[6]等人则提出了“双向直接偏好优化的安全后对其”方法，从正反两个维度优化模型对安全和非安全示例的偏好，能够有效缓解对话系统所存在的安全风险。

安全微调与后训练对齐：除了偏好的方法，直接基于训练数据进行监督微调 SFT 也是比较常用的手段。Gong [19]的研究指出，监督微调是“最好的方式”之一，因为其在塑造模型的行为有着更加强大的效果。然而，文中同时指出，过度的微调训练有可能会导致模型在可用性层面下降，尤其是在对非攻击性问题的回复中，可能会带来效用降低的问题。

持续性欺骗和后门威胁：尽管对齐技术在模型安全性提升的表现良好，但这种对齐技术本身也存在相对比较严峻的调整。OpenAI 的研究[4]发现，通过特殊训练，可以给 LLMs 植入“沉睡者”后门。而这些后门行为能够持久地逃过当前一些安全技术，其中就包括了监督微调、RLHF 在内的主流安全训练技术。这说明当前的对齐技术虽然能够有效的保证模型底层的安全性，但是在面对蓄意、隐蔽的恶意训练过程中，仍然存在一些根本性的漏洞，对齐的鲁棒性仍然需要加强。

2.2.2 外部防御与过滤系统

由于完全依赖模型内生安全来对外部的威胁进行抵御，存在较大的不可靠性，尤其是在不同的场景下，可能的安全性需求并不一定完全相同，因为安全性的需求而导致模型的可用性降低，这在很多场景下并不是被接受的。因而，有越来越多的学者在研究如何通过构建外部防御系统，来实现模型的防御，而这种方式在当前的产业界内已成为一种相对普遍的实践方式。这类的系统通常独立于模型服务，以第三方的方式进行运行。

基于规则与分类器过滤：这是最为传统的检测方式，通过关键词、正则表达式或者是预先训练好的机器学习分类模型（如 BERT）来对有害的内容进行检测[8]。这种方式通常为了覆盖场景范围的全面性，需要构建百万级别甚至千万级别的关键词、数千或数万的正则规则，来对有害内容进行检测。然而，在面临语种的不一致的时候，这种策略所需要的内置策略则又需要成倍的增加。因而在检测效果上存在一定的劣势。而通过分类器的方式，同样受限于分类样本的有限性，在有大量的、不同的风险的时候，仍然存在风险。但同样牟大恩等人提出[15]，通过构建基于这种有害指令的审核模型，设计大小

模型协同的文本审核框架，在一些风险的场景中，也能够实现精准高效的检测。

基于语义识别的深度检测：随着攻击手段的持续升级，攻击成本的降低，语义的隐蔽性持续增强，基于深度语义理解的检测方式也同样受到了重视，通过理解语义所想要表达的含义，来挖掘用户输入的潜在意图，从而激活安全审查机制[21]。在一些实验中同样显示，这样的方式也能够将越狱攻击的成功率大幅度降低，保障业务系统应用的安全性，提升其防御能力。

多层融合检测框架：为了应用更加复杂的攻击手法，多种检测技术结合的框架成为了一种趋势。Kokkula S 等人结合规则防护、BERT 分类器、大语言模型，构建一种多层防御的机制体系[8]，通过多级联动的方式对风险进行联动检测。实验表明，通过这种多层防御体系，能够有效降低检测的误报和漏报。在一些特定的防御场景，如在金融场景，梁快[20]提出了端到端的防御框架，包括提示词检测和改写模型，与上述不同，改写模型在针对一些风险性并不是特别高的问题下，能够通过将输入内容改写的更加安全进行防护，展示了这种防御方式的优势。此外，还有研究在输出层面，也在研究如何通过输出改写，使模型的输出更加的安全。

可验证性防御：为了提升防御手段的可靠性和有效性，可验证的防御是一个相对比较前沿的方向。Kumar A 等人 [5]提出了 erase and check 框架，这种框架从理论上能够保证对于经过验证的安全提示，模型是不会产生有害的输出。这种方式是一类通过数据证明、特征验证等手段来保障防御效果，区别于传统通过实验验证的方式，其核心优势在于确定其具备确定性和可追溯性。

2.2.3 红队测试与安全评估

以攻代守的红队测试，在传统的安全领域中已经相对比较成熟，在确保网络安全、数据安全、内容安全层面已经相对常见。在提升模型安全性层面，当前也是一种重要的驱动力，其核心在于通过自动化的、规模化的对抗性用例，通过查看模型输出的安全性，来评估和增强模型的鲁棒性。

自动化红队方法：早期的红队测试，过于依赖于人工进行构建恶意的提示词，这种方式虽然可行，同时具备较强的验证能力，但是其效率相对低下。而近年来，有机构[9]发布了大规模用于红队测试的数据集，可以系统化的对模型从各个维度进行安全性的测试。而同样在语言模型的多轮对话中，这种方式仍然存在一定的缺陷，因为模型输出的不固定性，通过固定的数据集很难验证出模型的脆弱性。但同样有研究[10]表明，基于“竞

争目标”和“泛化不匹配”的攻击方式，几乎能够在很多的测试提示上去的成功，揭示了安全机制存在的脆弱性情况。

多轮迭代与自适应测试：这是一种通过多轮迭代的方式对模型的安全能力进行提升，通过持续的生成对抗性提示，进而对模型进行安全性回复微调，从而实现安全与帮助同步进行提升[17]。同时 Xu 等人[22]在研究通过模型生成攻击，如 SCAV 框架，不仅仅能够实现比较高的攻击成功率，此外，其生成的攻击提示内容还能够跨模型、跨场景，并具备一定的可迁移属性，为评估多个模型缺陷提供了工具支撑。

安全基准与评估体系：如何进行模型安全性的衡量，很重要的一个手段是构建全面的评估基准和全面的评估用例，这是衡量模型安全性水平的基准。中文的安全性基准中文安全基准（ChineseSafe）[23]包含了超过 20 万个样本，覆盖了政治敏感性、色情内容、歧视内容、价值管内容等具有中文特色的安全类别，为评估中文大模型提供非常重要的知道作用。同时在这个过程中，也有一些其他学者在研究，通过全面的安全评估体系，对模型的安全性、可用性、可靠性、推理能力等各个属性构建综合衡量体系。

针对智能应用 Agent 测试：除了对推理模型进行测试外，对智能应用 Agent 进行安全性测试也非常重要。如今，智能应用不仅仅会调用模型能力，还会通过多智能体通信协议（Multi-Agent Communication Protocol, MCP）协议调用各个工具的能力，通过增强检索调用浏览器的能力，通过检索增强生成（Retrieval-Augmented Generation, RAG）调用知识库的能力。而则又揭露了一些新的安全性问题，尤其是间接的提示词注入[24]更是成为一种新型的威胁，更是拓宽了红队测试范畴。

2.2.4 隐私保护机制

大模型在训练过程中，会基于大量的语料进行训练，这其中同样存在很多大有敏感数据的信息，如身份证号、手机号、银行卡号等个人身份信息（Personally Identifiable Information, PII）。在内容生成过程中可能会记忆并泄露一部分训练数据的敏感数据，或者在推理过程中受到诱导攻击、角色扮演等攻击而将这些敏感数据输出，从而泄露用户隐私信息，这同样构成了另一个维度的安全挑战’

隐私风险分析：耿瑞利等人通过研究，系统性的构建出“风险维度-生成链路-影响层级”三位一体的的 LLMs 隐私分类框架[11]，同时基于该框架进一步提出“全域治理”策略，为大语言模型的隐私安全防护提供理论和实践的分析框架。

联邦学习框架下的隐私-安全协同：在隐私计算过程中，联邦学习（Federated Learning,

FL）是一种非常好的解决方式，FL 是一种分布式的机器学习范式，核心目标是在不集中传输和共享原始数据的情况下，让多个参与方能够联合训练一个全局模型，实现“数据可用不可见”。有学者提出了基于 FL 的大模型提示微调的方式来降低数据泄露的可能性，同时也基于攻击者的视角提出模型反演攻击方式，以便于更好的理解并防御隐私数据泄露。此外，李伟平等人聚焦于联邦学习过程中，对于密文数据的投毒检测与防御[25]，这同样也是相对新兴的一种检测方式。

推理阶段隐私保护：在模型推理的过程中，基于传统的数据安全的思路，以旁挂式系统，同样能够对隐私敏感数据进行检测。而最新研究表明，同样可通过结合 FL 的方式，来确保大模型推理过程中的安全性，旨在分析并防御推理过程中隐私数据泄露的风险[26]。

2.2.5 针对特定攻击防御

在大模型输入和输出的安全性研究中，提示注入和越狱攻击无疑式两个最指的关注的内容。两者经常交织存在，其中提示注入旨在诱导模型输入不安全的带有攻击性的内容，越狱攻击则试图突破模型原本预设的安全限制。此外，还有一些如植入后门攻击、幻觉威胁等常见的安全隐患。

越狱攻击防御：越狱攻击的防护以突破模型原本的安全防御规则，其防御手段通常需要结合内部对齐和外部安全检测。在内部对齐，通常通过强化学习（Reinforcement Learning, RL）、外挂式系统、监督微调的方式，但这些方式同样面临着一定的技术挑战，如上下文学习容易被诱导、状态空间难以证明等[13]。但同样，薛鋆豪提出了针对越狱攻击的“片段化动态防御方式[27]”，通过实际实验表明能够有效的降低攻击成功率，保护业务模型的安全性。

提示词注入防御：提示词注入式针对大语言模型的一个极为重大的威胁，除了前述的多层过滤系统外，博弈论的方法也被引入。Liu 等人通过构建极小极大[28]优化问题来提升对自适应提示注入攻击的检测性能。在针对智能体系统的注入中，BTBAS[29]框架通过自适应信息流的控制，兼具内容的安全性和业务的可用性。

后门攻击防御：后门攻击通常在训练阶段便已被注入恶意的触发器，马千里结合频域信息领域和内容安全领域的知识，创新型的提出了高度隐蔽的后门攻击方案[30]，在当前，这种攻击手段对安全检测提出了更高的要求，但可惜的式，目前尚未有普适性的高效防御手段。

幻觉缓解：幻觉问题虽然不是大模型安全的一个主流议题，但是大模型生成内容带有“幻觉”同样受到了安全研究的关注，其输出的内容带有事实偏差极有可能被攻击者恶意利用，用以传播虚假信息。何静研究，可通过知识注入、提示词微调、增强检索的方式[31]，降低在特定任务下模型输出内容的幻觉概率。

2.3 关键问题已解决的程度与尚待解决的难点

2.3.1 当前已解决的程度

基础对齐范式已确立：以 RLHF 和 DPO 为代表的安全技术路线已经确立，能够显著的增强模型回复的安全性，同时这种方式已成功用于主流的商用模型，能够有效降低模型在常见攻击手段下输出内容的违规率[3][16]。

外部防御体系有效性：结合规则、机器学习分类器、大模型的多级防御系统已成为一定的业界标准，能够对大部分的自动化攻击进行有效的防御[8]。

特定攻击的认知强化：对于提示词注入攻击、越狱攻击等攻击方式的原理、分类方式和基本防御手段已形成了较为系统的认知[27][28]。

2.3.2 尚待解决的难点

安全与业务的平衡：安全性的提升往往代表着需要系统模型的创造性和有用性。如何在设计过程中，在严格的安全约束下确保模型核心能力，是一个当前需要持续优化的难题[19]。

外挂式系统合规能力较弱：当前的外挂式系统主要聚焦于攻击领域的防护，然而如欧盟和中国，在政策合规[1][2]等层面对大模型落地同样提出了要求。通过系统化的建设，解决合规、攻击、信息泄露等场景的内容依旧是当前所需提升的能力。

对抗攻击的鲁棒性缺口：现有安全机制在面对不断变化的、变种的、基于强语义理解的对抗攻击中，仍然存在一定的脆弱性。攻击具备很高的成功率，而防御仍然处于一种被动与追赶的状态[22][32]。

评估标准和体系的碎片化：当前国内外缺乏相对权威的安全评估标准，对于不同维度的风险评估难以有一个统一的基准。不同研究使用的数据集、攻击手法和评估指标存在差异，从而导致结果难以进行有效的对比，也导致如何评估模型的安全性缺乏公认的

度量[33]。

针对上下文防御的不足：在一些依赖于上下文，通过分布诱导方式实现的复杂攻击时，现有的检测方式或防御手段仍然存在检测能力的缺失[31]。

隐私保护与模型安全的挑战：联邦学习与差分隐私虽然能够在一定程度上解决模型输出隐私数据的情况，但却容易成为影响模型性能的方式；然而安全对齐技术又可能引入隐私泄露的风险，如何进行协同优化仍然是一个代表性问题[11][34]。

智能体与多模态场景的安全问题：现有的防御技术主要时针对文本进行安全防御，对于能够主动调用工具、主动进行多轮对话规划、理解音频、视频、图片等多模态场景下的智能体，其攻击面仍在持续加剧扩大[30]，如间接提示词注入，当前的动态、实时防护体系仍处于起步阶段。

2.4 未来发展的趋势

基于当前研究现状与挑战，未来大模型内容安全防护研究将呈现以下趋势：

1. **朝向可证明与可验证的安全：**如 Kumar [5]所倡导的，未来的防御技术将不仅仅追求高的经验性拦截率，更追求在特定威胁模型下提供形式化的安全保证，使安全性变得可度量、可验证。

2. **轻量级与高效率的防护：**随着模型在边缘设备部署，对防御系统的开销提出苛刻要求。研究将更关注参数高效微调（如低秩适配（Low-Rank Adaptation, LoRA）变种）、轻量级检测模型[28]以及高效的推理时防御算法，以实现低延迟、低资源消耗的安全防护[26]。

3. **自适应与自动化安全循环：**结合持续学习的理念，未来的安全体系将是一个能够自动从新攻击中学习、动态更新防御策略、并闭环迭代模型参数的自动化系统。多轮对抗红队微调（MART）[17]等迭代式红队微调方法已预示了这一方向。

4. **治理框架与标准化：**技术研究将与治理需求深度融合。学术界与产业界将合作推动安全基准、评估协议、审计标准乃至“安全护栏”[4][11]技术规范的建立，形成类似《大模型安全实践》[35]报告提出的“五维一体”治理框架，促进安全生态的健康发展。

5. **跨领域风险的综合治理：**内容安全将与隐私安全、系统安全（如对抗样本）、应用安全（如智能体）等更紧密地结合。研究将更多地从“全栈安全”[36]或“全域治理”[11]的视角出发，设计一体化的解决方案，以应对 AI 系统日益复杂的风险图谱。

3 结论

大模型正处于一个快速演进、快速发展的阶段，其安全性问题的研究同样需要快速跟进。本文基于对国内外近年来的文献进行综合研究，梳理出安全对齐、旁挂防御、红队评估、隐私保护、转向场景防御共五大技术分支，详细阐述每个分支下的主流方法、技术现状及代表性方式。分析表明，当前研究在基础对齐、自动化测试和特定场景下的攻击研究已取得了一定性的进展，为大模型的安全鉴定了一定的基础。

然而，领域中仍然面临着一系列的固有挑战，如安全与业务平衡的矛盾、对抗性攻击下的鲁棒性确实、评估标准呈现碎片化缺乏标准化、上下文安全防御手段不足、隐私保护与安全协同等那题，这些共同构成了当前防护体系下的难点。此外，这些难点并非单独孤立存在，它们彼此交织，要求研究者人员具备较强的领域视角与系统性的思维。

展位未来，该领域的研究将持续朝着可验证性发展，发展高效且兼顾业务的防护技术，构建自动化的安全闭环，推动标准化框架落地等方向，此外，在多模态、具身智能、世界模型等的发展下，安全问题需要不断跟进，着不仅有赖于跨学科的合作，更要求在行业内乃至全球进行协同治理。只有不断的通过技术创新与规范治理进行双重驱动，才能够持续有效的构建大模型发展的安全基石，使大模型能够真正的造福于人类社会。

参考文献

[1] 欧洲议会与欧盟理事会.人工智能法: Regulation (EU) 2024/1689 of the European Parliament and of the Council of 13 June 2024[Z/OL]. 欧盟官方公报, 2024[2024-06-13]..

[2] 生成式人工智能服务管理暂行办法[J].中华人民共和国公安部公报,2023,(05):2-5.

[3] Bai Y, Kadavath S, Kundu S, et al. Constitutional ai: Harmlessness from ai feedback[J]. arXiv preprint arXiv:2212.08073, 2022.

[4] Hubinger E, Denison C, Mu J, et al. Sleeper agents: Training deceptive llms that persist through safety training[J]. arXiv preprint arXiv:2401.05566, 2024.

[5] Kumar A, Agarwal C, Srinivas S, et al. Certifying llm safety against adversarial prompting[J]. arXiv preprint arXiv:2309.02705, 2023.

[6] 李卓君.面向大语言模型的安全性对齐技术研究[D]. 黑龙江:哈尔滨工业大学,2025.

[7] 赵月,何锦雯,朱申辰,等.大语言模型安全现状与挑战[J].计算机科学,2024,51(01):68-71.

[8] Kokkula S, Divya G. Palisade--Prompt Injection Detection Framework[J]. arXiv preprint arXiv:2410.21146, 2024.

[9] Ganguli D, Lovitt L, Kernion J, et al. Red teaming language models to reduce harms: Methods, scaling behaviors, and lessons learned[J]. arXiv preprint arXiv:2209.07858, 2022.

[10] Wei A, Haghtalab N, Steinhardt J. Jailbroken: How does llm safety training fail?[J]. Advances in Neural Information Processing Systems, 2023, 36: 80079-80110.

[11] 耿瑞利,李皖,李森涛.主体协同、全域治理：大语言模型的隐私风险类型与应对策略研究[J/OL]. 电子科技大学学报(社科版),1-13[2025-12-11].https://doi.org/10.14071/j.1008-8105(2025)-5022.

[12] Pang S, Lu Z, Wang H, et al. Reconstruction of differentially private text sanitization via large language models[J]. arXiv preprint arXiv:2410.12443, 2024.

[13] 詹妮弗, 戈福思, 张日崇. 保护大语言模型免受越狱攻击[J]. 计算, 2025, 1(6): 101-102.

[14] 任奎, 王志波, 秦湛, 等. 大语言模型越狱攻击与防御[J]. 计算, 2025, 1(7): 55-61.

[15] 牟大恩,卫志华,孙铭隆,等.面向金融领域大语言模型的提示注入攻击防御机制研究及应用[J].网络与信息安全学报,2024,10(05):119-133.

[16] BAI Y, JONES A, NOVIKOVA I, 等. 基于人类反馈强化学习训练有益且无害的助手[J/OL]. arXiv, 2022[2022-04-12]. https://arxiv.org/abs/2204.05862.

[17] Rafailov R, Sharma A, Mitchell E, et al. Direct preference optimization: Your language model is secretly a reward model[J]. Advances in neural information processing systems, 2023, 36: 53728-53741.

[18] Liu Z, Sun X, Zheng Z. Enhancing llm safety via constrained direct preference optimization[J]. arXiv preprint arXiv:2403.02475, 2024.

[19] Gong Y, Ran D, He X, et al. Safety misalignment against large language models[C]//Proceedings of the 2025 Annual Network and Distributed System Security Symposium (NDSS). 2025.

[20] 梁快.Prompt 分类器：基于语义和意图识别的提示词防御策略[D].广州大学,2025.DOI:10.27040/d.cnki.ggzdu.2025.001909.

[21] 刘会,朱正道,王淞鹤,等.基于深度语义挖掘的大语言模型越狱检测方法研究[J].信息网络安

全,2025,25(09):1377-1384.

[22] Xu Z, Huang R, Chen C, et al. Uncovering safety risks of large language models through concept activation vector[J]. Advances in Neural Information Processing Systems, 2024, 37: 116743-116782.

[23] Zhang H, Gao H, Hu Q, et al. Chinesesafe: A chinese benchmark for evaluating safety in large language models[J]. arXiv preprint arXiv:2410.18491, 2024.

[24] Greshake K, Abdelnabi S, Mishra S, et al. Not what you've signed up for: Compromising real-world llm-integrated applications with indirect prompt injection[C]//Proceedings of the 16th ACM workshop on artificial intelligence and security. 2023: 79-90.

[25] 李伟平.面向联邦学习的密文数据投毒检测方法与防御策略分析[D].广州大学,2025.DOI:10.27040/d.cnki.ggzdu.2025.000299.

[26] 贾晓聪.用于场景级应用的联邦增强及安全大模型[D].齐鲁工业大学,2025.DOI:10.27278/d.cnki.gsdqc.2025.000632.

[27] 薛鋆豪.大语言模型越狱与后门攻防研究[D].杭州电子科技大学,2025.DOI:10.27075/d.cnki.ghzdc.2025.000445.

[28] Liu Y, Jia Y, Jia J, et al. DataSentinel: A Game-Theoretic Detection of Prompt Injection Attacks[C]//2025 IEEE Symposium on Security and Privacy (SP). IEEE, 2025: 2190-2208.

[29] ZHONG P Y, CHEN S, WANG R, et al. Rtbas: defending llm agents against prompt injection and privacy leakage[J/OL]. arXiv, 2025[2025-02-12].

[30] 马千里.基于频域信息的人工智能后门安全问题研究[D].内蒙古工业大学,2024.DOI:10.27225/d.cnki.gnmgu.2024.000275.

[31] 何静,陈逸然,戴田宇.基于谣言传播机制的大模型幻觉减轻策略[J].实验技术与管理,2025,42(02):96-103.DOI:10.16791/j.cnki.sjg.2025.02.014.

[32] Wu Y H, Xiong Y J, Zhang H, et al. Sugar-coated poison: Benign generation unlocks llm jailbreaking[J]. arXiv preprint arXiv:2504.05652, 2025.

[33] 陈沫.面向大语言模型的黑盒对抗性攻击与防御关键技术研究[D].电子科技大学,2025.DOI:10.27005/d.cnki.gdzku.2025.004756.

[34] 吕光通.联邦学习驱动的场景级边缘大模型优化及安全应用研究[D].齐鲁工业大学,2025.DOI:10.27278/d.cnki.gsdqc.2025.000709.

[35] 清华大学人工智能研究院．大模型安全实践[R/OL]．北京：清华大学，2025[2024-12-01]．https://13115299.s21i.faiusr.com/61/1/ABUIABA9GAAg_vvntQYogK7G1gM.pdf

[36] Wang K, Zhang G, Zhou Z, et al. A comprehensive survey in llm (-agent) full stack safety: Data, training and deployment[J]. arXiv preprint arXiv:2504.15585, 2025.