北京航空航天大學 COLLEGE OF SOFTWARE BEIHANG UNIVERSITY 软件学院

专业硕士学位论文

开题报告

面向 AI Agent 安全的多级外挂式检测方法研究

作 者 姓 名　金祺昌

作 者 学 号　ZF2421105

专 业 名 称　软件工程

学院指导教师　胡峻林副教授

企业实习导师　邵菊产品技术总监

企业实习导师单位　三六零安全科技股份有限公司

培 养 学 院　软件学院

论文起止时间　2025 年 9 月 ~ 2027 年 6 月

开题报告提交时间　2025 年 10 月

目 录

1 课题来源和意义 2
1.1 课题来源 2
1.2 课题背景 2
1.3 选题意义 3
2 国内外相关研究现状与最新发展动态 4
2.1 外挂式检测系统发展情况 4
2.2 智能应用 Agent 长文本检测的研究现状 6
3 论文研究方案 8
3.1 研究目标 8
3.2 研究内容 8
3.3 拟解决的关键问题 9
3.4 拟采取的技术方法与研究路线 10
3.5 可能的创新之处 15
4 预期达到的目标和研究成果 15
4.1 预期目标 15
4.2 预期成果 15
5 论文工作计划 16
参考文献 16

1 课题来源和意义

随着人工智能（Artificial Intelligence：AI）技术的快速发展，大模型的广泛应用，基于大模型的智能应用在近年来也快速在各行各业得到了广泛的应用。尤其是大语言模型（Large Language Models：LLMs）的兴起，使得文本生成、对话交互、智能助手等各应用场景日益丰富。

然而，人工智能智能体（AI Agent）应用在带来便利的同时，也面临着合规、内容攻击等安全挑战，而多智能体（Multi Agent）、多智能体通信协议（Multi-Agent Communication Protocol：MCP）工具等的广泛发展更是引入了新的安全风险。

1.1 课题来源

本课题源于当前生成式人工智能（Generative Artificial Intelligence：AIGC）与 AI Agent 技术在实际业务场景中规模化应用所面临的核心安全与合规挑战，随着以 ChatGPT、QWEN 等为代表的大语言模型 LLM 能力的突飞猛进，其与人类价值观的安全对齐问题已成为学术界和工业界的核心关切。[1]。然而，即便是经过安全对齐的模型，在实际生产的环境中，仍面临着越狱攻击、提示词注入[2]及生成内容有害等多重风险，我国《生成式人工智能管理暂行管理办法》更是将其划分为 5 大类 31 小类的风险[3]。而这些风险在智能应用的复杂和开放交互环境中又进一步被放大。传统的单一检测手段或内生安全机制在应用更加复杂场景的攻击时往往难以有效应对。因而，构建一个高效的、鲁棒性强的外挂式安全检测系统，是保障智能应用合规、安全、可落地的关键技术需求，也是本课题的直接目标。

1.2 课题背景

大语言模型的广泛应用在带来生产力变革的同时，引发了严峻的安全治理挑战。一方面，模型可能生成涉政、偏见、歧视、虚假甚至违法的有害输出[4]。另一方面，攻击者可通过精心构造输入来突破模型预设的安全规则，执行有害行为[5]。OpenAI 为此专门设立了安全对齐团队，投入大量的算力用来解决该问题[6]，国内外也发布了一系列法规，如欧盟的《人工智能法》，我国的《生成式人工智能暂行管理办法》[3,7]，均明确要求服务提供者需要承担内容安全的主体责任。

在技术层面，现有的安全防护方案主要包括内生安全体系搭建和外挂式安全检测两

条路径。内容安全主要通过指令微调、人类反馈强化学习（Reinforcement Learning from Human Feedback：RLHF）、直接偏好优化（Direct Preference Optimization：DPO）等技术，在模型训练和微调层面就塑造模型自身的安全价值观[8,9]。外挂式安全检测则主要通过在模型输入和输出端构建独立的检测模块，实现内容的审查和过滤，主要的技术方法包括基于关键词的匹配技术、基于传统机器学习的分类模型、基于 LLMs 的分类器[10]。然而两条路径各有局限，如内容安全体系可能由于过于兼顾安全而影响了模型的性能，规则方式在检测过程中由于耗时过大影响了用户的体验。

而更为严峻的是，随着 AI Agent 应用的发展，用户的输入、工具的输入、知识库的输入等在 Agent 框架中均可作为模型的输入，使得在交互过程中产生得上下文变得非常冗长，远远超过了传统分类模型的常规处理长度。而长文本的输入导致语义信息分散、关键风险隐蔽，给检测带来了额外的困难[10]。

因而，在当前 Agent 发展迅猛的阶段下，如何设计一个能够高效处理长文本的、融合多种检测优势、兼顾业务与安全的多级混合检测系统，以应对 AI Agent 应用合规、安全的落地，成为智能体 AI Agent 应用落地的迫切需求。

1.3 选题意义

本研究选题主要体现在以下几个方面：

丰富智能应用安全防护体系：本研究提出的外挂式混合检测系统架构，将敏感词规则、传统机器学习模型、大模型深度结合，探索三者协同工作的理论框架和效能体现，为构建多层次、自适应、可解释的内容安全防护体系提供更新的理论思路。

深化长文本内容安全风险理解：针对智能体 AI Agent 应用场景下面临的上下文输入、长文本输入等问题，系统研究其安全风险问题，提供相关的检测与处理方法，推动大模型输入内容研究从“短文本单点检测”向“长文本全局理解”进行演进。

探索兼顾业务与安全的协同机制：研究如何结合敏感词的高效性、机器学习模型的准确性、大语言模型的深度性进行有机融合与优势互补，形成“快-准-深”的协同检测框架。

提升监管与治理能力：为企业和监管部门提供一套自动化、智能化的内容审计与风险预警工具，有助于及时发现和处置利用智能体 AI Agent 应用进行的恶意活动和不合规动作，促进人工智能产业的健康、有序发展。

有效应对现实环境中的安全威胁：本研究旨在同时解决合规红线和内容攻击的两大核心问题，同时针对智能体 AI Agent 中经常出现的长文本输入问题进行探索解决，满足实际业务场景中对效率、安全的双重要求。

为智能应用提供可落地的安全围栏：本文所研究的方法，以提供外挂系统的方式，无需对原有模型的训练层进行修改，具有部署灵活性、兼容性强的特点，对于各类已经部署或正在开发的智能体 AI Agent 应用进行快速赋能，降低其合规风险。

2 国内外相关研究现状与最新发展动态

2.1 外挂式检测系统发展情况

外挂式检测系统作为模型不受后的重要安全屏障，其发展经历了从简单规则到智能学习的演进。早期研究主要依赖于基于关键字的过滤方法。例如，通过构建敏感词黑名单、正则表达式来拦截明显有害查询。这种方法简单高效，但极易被同义词替换、句式变换等简单对抗手段绕过。随后，基于机器学习的分类器成为主流，研究人员利用传统的文本分类模型，如支持向量机（Support Vector Machine：SVM）、随机森林、双向编码器表示转换器（Bidirectional Encoder Representations from Transformers：BERT）或极端梯度提升（Extreme Gradient Boosting：XGBoost）等等机器学习分类器来检测提示注入攻击。随后，随着大语言模型 LLM 的进一步发展，有学者利用语言模型所具备的深度语义理解，应用在内容输入输出的检测上，使得其对于复杂语义的理解的效果提升了很多。

Kokkula 等人[11]提出的 Palisade 框架，利用三层串联检测检测机制，只有通过三层检测判定无风险的提示词，才会传递给目标 LLMs。其中第一层通过基于规则的方式进行启发式检测；第二层基于分类器 BERT 的方式进行二分类检测，能够有效对于有恶意特征但规则层面未检测出的恶意提示词；第三层采用独立 LLMs 进行审查，采用应用程序接口（Application Programming Interface：API）调用如 Llama 模型作为审查员，要求其扮演安全检测员的角色来判断是否为提示词注入的方式。整体逻辑采用逻辑“或”的关系，确保将漏报降为最低。这种思路为后续的研究和工业界部署提供了很好的思路。然而，很显然在实际工程落地的角度，通过串联三层检测的机制，难免加长整个检测路径，增强延迟从而影响用户体验。

Rajathi 等人[12]提出采用两阶段堆叠集成模型，结合非参数分类器和参数分类器作为混合学习模型，而非“黑箱”式的选择模型，其中非参数模型能够灵活捕捉复杂未知的数据模式，但是其计算复杂；而参数模型则提供稳定、平滑的决策边界，可以有更加高效和可解释性强的优点。这种方式在对比传统风险的检测过程中，能够有效的实现高精度和低误报。这种研究为本文的研究同样提供了借鉴想法，但是其主要应用在对比传统入侵检测系统（Intrusion Detection System：IDS）等产品的检测，在当下提示词攻击层面仍需进一步进行实验。

Zhang 等人[13]则旨在实现对齐、可定制和可解释的 LLMs 安全检测器，其核心还是通过构建大量的数据集，通过训练和微调构建检测结果。与其他研究不同的是，除了生成检测的结果，如安全和不安全外，还会输出相应的检测依据，即解释性分析。这种方式，主要基于模型侧的方式进行检测，但是对于模型的“黑箱决策”进行了优化。然而不难想象的是，由于模型的推理，势必会影响其检测即时性。

Ghosh 等人[14]则主要提出了一套从数据构建、模型训练到部署框架的完整 AI 内容解决方案，为解决 LLMs 内容安全的数据稀缺，模型泛化、动态适应等挑战提供了系统化的方法和工具。研究从方案层面为本文后续的研究提出了很多框架性的理解，让本文在构建整体思路过程中，有了更加明确的方向。

Liu 等人[15]提出了基于博弈论框架的提示攻击检测方法 DataSentinel，其将检测的 LLMs 的微调形式化为一个极小极大优化问题，提出一种交替优化求解方案。DataSentinel 通过一种巧妙的博弈策略，将检测模型的脆弱性转换为检测优势，通过模拟最强自适应攻击者进行训练，从而实现了对现有及自适应提示攻击的高召回率检测。这项研究为为 LLMs 的安全性保护提供了一个创新的防御思路。

综上所述，外挂式检测系统已从早期的关键词匹配演进为基于机器学习和深度学习的混合检测模式，检测精度显著提升。然而，现有研究在面向实际生产环境时仍存在显著局限。

一是时效性与准确性的矛盾未解：现有的多级检测多采用简单的串联（逐级过滤）或并联（全量检测）架构；而串联架构在面对深层攻击时链路过长，导致显著的延迟累积；并联架构则造成算力资源的极大浪费，难以满足高并发业务需求。

二是缺乏动态调度机制：大多数系统对所有输入一视同仁，缺乏根据输入内容的难

易程度动态调整检测深度的能力，无法在“快”与“准”之间找到动态平衡点。

三是对新型攻击泛化能力不足：传统分类器难以应对基于逻辑陷阱或角色扮演的复杂提示词注入，而单纯依赖大模型进行检测又面临成本高昂的问题。

2.2 智能应用 Agent 长文本检测的研究现状

随着大语言模型的快速发展，学者们设计了多种架构，结合大语言模型进行生产力的提升，这其中比较突出的当属智能体 AI Agent 应用，从简单的 AI Agent 应用，到自主规划性的 AI Agent，再到如今相对比较火热的智能体蜂群。而国内互联网厂商三六零发布的 L4 级智能体蜂群更是将智能体推到一个比较新的高度。

与简单的大语言模型不同，智能体 AI Agent 能够主动的进行工具调用，主动进行知识库调用，主动进行业务内部、外部的工具调用，甚至还可以通过 MCP 协议调用其他的 AI Agent，其与内外部的环境交互变得更加的复杂。其中比较代表性的威胁为间接提示词注入，攻击者通过预先将攻击指令植入到 Agent 可能检索到的外部数据源，当 AI Agent 读取这些数据时，智能被激活并篡改其行为目标[16]。这突破了传统直接输入攻击的边界，防御难度极大。此外，其中另一大挑战，则是 AI Agent 在使用过程中，使用的文本长度有了更大的提升，而传统仅对于前 512 个字节进行检测的方式，则很难对于现有的威胁进行有效的防御。

ZHONG 等人[17]设计基于信息流控制的大语言模型智能体防御方案（RTBAS）的解决方案，其核心思想是选择信息流控制（Information Flow Control：IFC），通过依赖关系筛选器识别与当前决策相关的区域，只对这些区域进行安全元数据传播，无关区域责备隐蔽。其将信息流控制思想创造性的应用到基于大语言模型的智能体系统（TBAS）中实现信息流追踪。同时，通过大量实验验证，RTBAS 能够有效的抵御提示注入和隐私泄露，在安全和实用性取得平衡，这为构建安全、可用的 AI Agent 提供了可行的方案。然而这种方式需要开发者预先为工具和消息等均定义安全标签和策略，增加了一定的开发负担。

刘会等人[18]则基于文本分段与语义聚合策略来解决长度超限的问题，通过将长文本按照语义边界进行分段，如段落、标点等，每一段作为独立的子样本，对于子样本进行恶意预测后，再通过“加权投票”的方式进行结果融合。确保了分段后单批处理的 Token

量减少，避免了长文本导致的显存溢出（Out Of Memory：OOM）。该方式解决了长度超限和效率低两大痛点，为本文的后续研究提出了相对可行的参考方法。

沈晓晨[19]提出了 MLAISO 框架，旨在解决人工智能安全领域数据来源广泛、种类复杂且缺乏统一规范描述的问题。这个框架将本体分为三个层次，分别是原理层、问题层和措施层。其中一种方案便是通过将长文本构建为事件图或语义关系图，再结合安全知识图谱进行推理，其研究为进行长文本中存在攻击行为提供了一种思路。

夏鸿斌等人[20]聚焦传统生成式对抗网络（Generative Adversarial Networks：GAN）的研究对长文本生成的缺陷，通过“自注意力机制与卷积神经网络（Convolutional Neural Network：CNN）融合”的关键创新，使得 CNN 模型能够捕捉文本的全局语义信息，解决了全局语义捕捉和引导信号系数的问题，通过实验验证了模型的有效性。这种方式为实际场景中的长文本生成任务提供了高性能的技术方案，在工业工程领域具备较为不错的应用潜力。

薛鋆豪[2]使用滑动窗口将长输入，尤其是代码形态的攻击载荷分割为多个重叠的片段，对每个片段进行独立的轻量化的风险评估，同时融合所有片段的评估结果，做出最终的决策。这种方法在保证局部语义完整性的同时实现了全文的覆盖，也为文本后续的研究提供了极为不错的指导意义。

牛犇等人[21]采用罗伯塔预训练模型（RoBERTa）预训练模型作为底层解码器，在隐私政策合规层面，将输入内容按句子或短语拆分，让 RoBERTa 捕捉每个文本片段的上下文语义向量，突破了传统文本处理的词袋局限，能够捕捉到深层语义中的上下文信息。这种方法对于语义分割的精准度有较强的要求，因为其直接决定了后续合规检测的准确率。

综上所述，现有针对长文本的研究主要集中在滑动窗口、信息流控制及注意力机制优化等方面，虽然在一定程度上缓解了模型处理长度的限制，但在 AI Agent 特有的复杂交互场景下仍显不足。

一是语义割裂问题严重：传统的定长切分或滑动窗口机制往往忽略了文本的内在逻辑结构（如代码块、JSON 格式），容易导致跨段落的攻击载荷被截断，从而产生漏报。

二是缺乏对异构数据的统一处理：AI Agent 的输入包含用户指令、工具返回结果（结构化数据）、知识库文档（非结构化数据）等多种模态。现有方法多针对单一文本流，缺

乏对这种多源异构数据的针对性检测策略。

三是检测效率难以支撑超长上下文：随着 Agent 记忆和 RAG 检索内容的无限增长，全量扫描的计算开销呈线性甚至指数级增长。如何在不牺牲安全性的前提下，实现对超长上下文的“重点检测”或“快速筛选”，尚缺乏成熟的解决方案

3 论文研究方案

3.1 研究目标

本课题旨在构建一套面向 AI Agent 复杂交互场景的基于抢占式调度的多级外挂式安全检测系统，重点解决当前大模型应用在长文本输入环境下“高检出率”与“低延迟”难以兼顾的难题。具体研究目标如下：

一是构建多级异构协同检测架构：突破传统串行或并行检测的局限，设计融合“规则匹配、轻量级机器学习、大语言模型”的三层异构检测体系。旨在实现对于 AI Agent 风险输入的高效、准确防御。

二是攻克长文本语义完整性检测难题：针对 AI Agent 中常见的超长上下文（如 RAG 检索、工具调用日志），提出基于“结构化语义切片”与“滑动窗口”相结合的预处理方法。目标是在将长文本高效分块的同时，最大限度保留语义完整性，避免因切分导致的漏报。

三实现高并发下的低延迟响应：引入操作系统领域的“抢占式调度”思想，设计异步并行的任务分发与熔断机制。目标是实现系统在处理 AI Agent 输入时能够快速响应，在面对复杂攻击时能进行深度防御。

3.2 研究内容

为实现上述目标，本研究将围绕 AI Agent 安全检测中的架构协同、长文本语义保持及动态调度效率三大核心问题展开深入研究。

（1）多级外挂式检测系统整体设计：本研究首先面向 AI Agent 真实链路，如用户输入、工具 MCP 调用、知识库增强检索、浏览器检索等梳理“可进入模型上下文的文本/结构化消息”，建立统一的检测入口，避免仅检测用户输入导致的防护盲区。其次整个系统采用外挂式部署，不修改业务 LLM 及 AI Agent 的逻辑编排，通过 API 方式接入，保证对不同业务均可落地。检测框架设计为“规则层-机器学习层-大模型层”的多级结构，

并明确每一级的职责边界，如规则层负责红线合规及显性攻击的快速拦截，机器学习层负责高频风险的分类判别，大模型层负责复杂语义等相关的攻击识别。在工程维度，输出统一的标签体系，如涉政、暴恐、色情、辱骂、提示注入、等，并分别定义每一类的建议处置策略，如放行、拒答、观察等。在任务调度层面引入“多级触发与调度策略”，避免简单的串联导致延迟爆炸，如规则层命中高风险后，引入“剪枝”策略快速跳过机器学习层与大模型层，实现延迟降低。

（2）长文本专用检测方法设计：针对 AI Agent 场景常见的“超长上下文”，如多轮对话、检索内容、工具输出拼接等，研究将长文本检测从单段输入分类转化为“分块检测+语义切分”的问题，以解决长度超限、延迟过高等问题。提出“滑动窗口分块”机制，设定窗口长度 w 与重叠比例 r，确保跨边界攻击在窗口中完整出现。提出“语义边界切片”机制，结合段落、标题、章节、符号等，先做结构化切片，再叠加前述提出的“滑动窗口分块”机制，整体实现“结构优先、语义完整”，从而降低整体漏报。基于上述的“分块”与“切片”机制，采用并行化处理，将处理后的待检测任务提交到检测系统中进行并发执行，同时设置超时和熔断机制，确保在高并发业务场景下能够有稳定的处理表现。引入“局部风险与全局风险”融合策略，如针对块内返回的高风险后，终止任务执行，降低平均延迟。

（3）抢占式调度的动态决策与融合机制：为平衡检测的准确性与业务的低延迟需求，研究各级检测器之间的协同调度与结果融合策略。采用抢占式调度策略：引入“并行处理+剪枝”机制，避免全量计算。当规则层或机器学习层以高置信度命中风险时，立即触发“中断信号”，终止后续大模型层的推理任务，实现快速拦截或放行。引入局部与全局风险融合，针对长文本分块后的检测结果，确定“局部风险决定全局”逻辑。一旦任意分块被判定为高危，即终止整体任务并返回风险标签；对于全部分块均为低风险的情况，则通过加权投票机制生成最终的安全评分。

3.3 拟解决的关键问题

（1）长文本环境下的精度与效率平衡问题：如何在不增加延迟、不降低检测精度的前提下，确保对于数万词元（Token）的输入文本进行有效的、全面的安全检测，避免因信息截断导致的漏报及因安全检测而导致的延迟问题。

（2）多级检测方法的协同与决策问题：如何设计各级检测器之间的触发条件、信息

传递与决策融合规则，以最小化总体计算开销，保证业务的可用性和连续性，同时确保在复杂攻击面前的高检出率。

（3）对新型和自适应的攻击的检测问题：如何设计系统，确保不仅仅对于已有明显特征的攻击手法、方式进行检测，还能够有效应对如上下文感知攻击、间接提示词注入等新型、隐蔽的攻击手法。

3.4 拟采取的技术方法与研究路线

针对 AI Agent 应用场景中“长文本上下文输入”、“高并发低延迟要求”与“复杂攻击手段隐蔽”之间的矛盾，本研究提出一种基于抢占式调度的并行异构检测架构（Preemptive Parallel Detection Architecture）。该架构的核心设计理念是“以空间换时间”与“动态算力分配”。通过并行化执行不同量级的检测任务，利用轻量级模型（规则/ML）的快速响应特性，对重量级模型（LLM）的执行过程进行动态干预（抢占/中断）。在保证对复杂攻击具备深度推理能力的同时，最大程度降低常规流量的检测延迟与算力成本。

系统整体逻辑架构图如图所示：

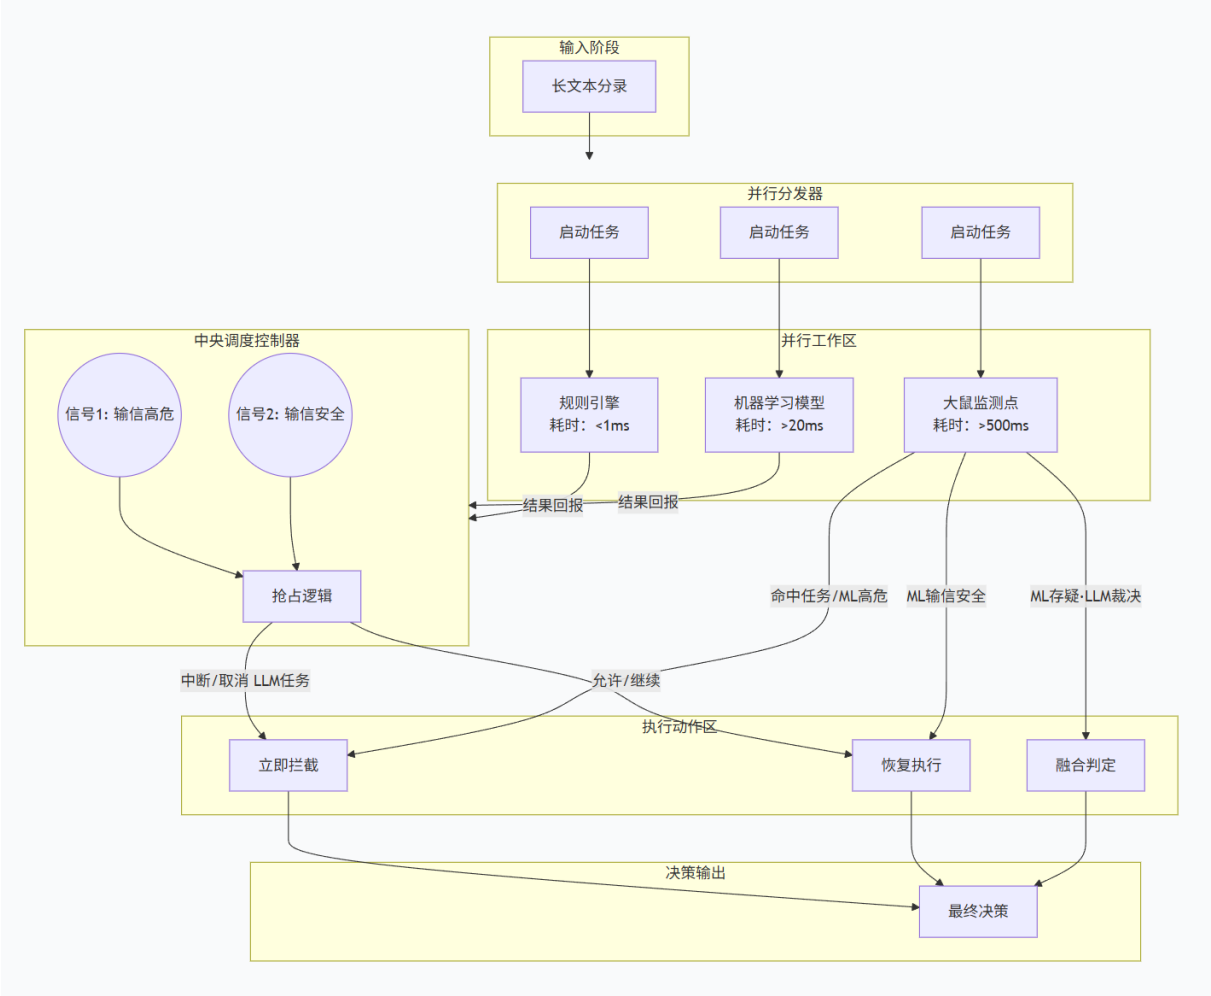

图 1.1　基于抢占式调度的并行检测系统总体架构

以下将对架构中的关键模块与机制进行详细阐述：

（1）输入阶段：长文本结构化切分与分发

在 AI Agent 应用中，输入内容往往包含用户指令、RAG 检索文档、工具返回结果（JSON/XML）等多源异构数据，且长度极易超过单模型的处理窗口。因此，输入阶段的核心任务是“分块语义切分”与“并行任务分发”。

结构化语义切分（Structure-Aware Splitting）：本研究摒弃简单的定长截断，采用“结构优化、滑窗兜底”的策略。首先解析文本结构，如 Markdown、代码块、JSON 字段，保证关键语义单元，如一段完整的攻击代码或 Prompt 指令不被切断。对于结构化切分后依然超长的片段，采用采用滑动窗口机制，设定窗口大小 W（如 512 Tokens）与重叠率 O（如 15%），生成重叠的文本切片（Chunk），确保跨边界的攻击载荷能够被完整捕获。

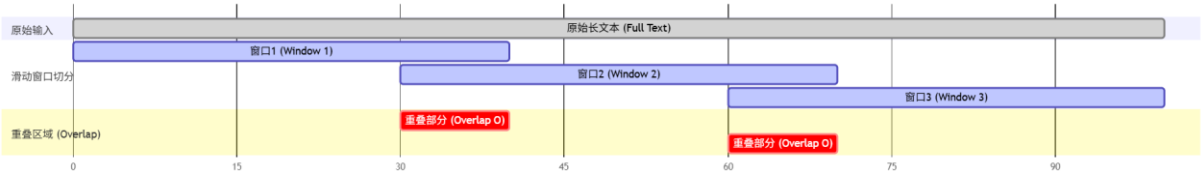

图 1.2　长文本滑动窗口示意

元数据标记与分发：切分后的每个 Chunk 被标记元数据标签（Source Tag），标记其来源，随后，并行分发器（Parallel Dispatcher） 采用异步 I/O 模型（Asynchronous I/O），将所有 Chunk 同时推送到后端的三个检测引擎中。分发器不等待结果，而是立即释放控制权，确保三个检测通道几乎同时启动。

（2）检测阶段：三层异构并行引擎

本架构设计了三个在原理上正交（Orthogonal）的检测通道，分别负责捕捉不同维度的风险特征。它们在“并行工作区”中独立运行，互不阻塞。

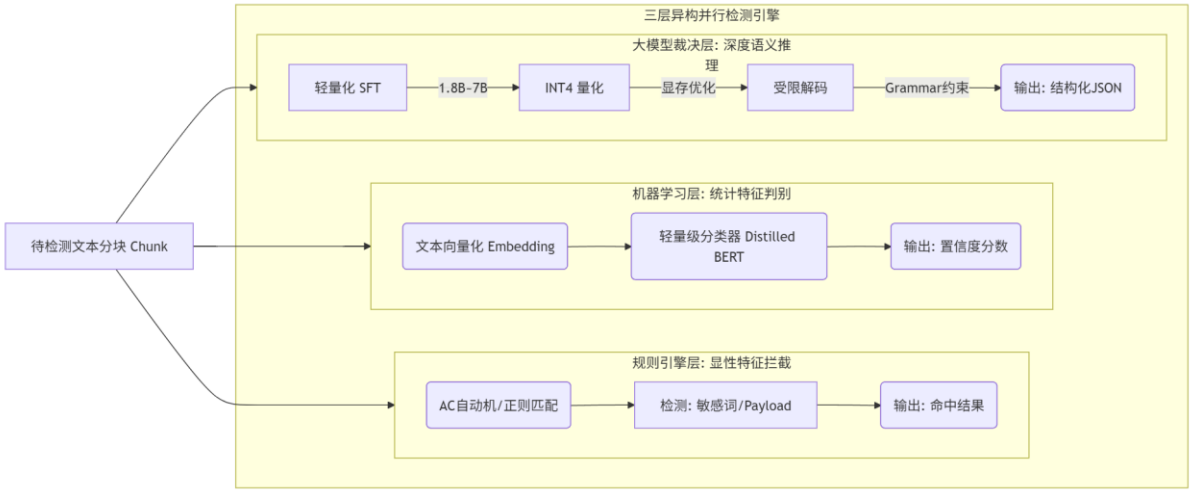

图 1.3　三层异构并行引擎示例

规则引擎层，旨在实现极速拦截已知攻击与合规红线。基于 AC 自动机（Aho-Corasick Automaton）算法与 DFA（确定有限状态自动机）正则引擎，并行扫描所有 Chunk。重点检测涉政敏感词、明确的恶意 Payload 签名（如 SQL 注入关键字 UNION SELECT、Shell 指令 rm -rf）、以及常见的 Prompt 注入模板（如“Ignore previous instructions”）。该层具备 $O(n)$ 的时间复杂度，确保在微秒级完成扫描。

机器学习层，旨在识别具有统计规律的泛化攻击与正常内容的快速放行。采用知识

蒸馏（Knowledge Distillation）技术，将 BERT 等大模型的知识迁移至轻量级模型（如 FastText 或 DistilBERT），将文本映射为高维语义向量进行分类。该层不依赖具体关键词，而是通过语义分布判断风险（如辱骂、色情、垃圾广告）。重要的是，该层会输出一个置信度分数（Confidence Score），这是后续调度决策的核心依据。

大模型裁决层，旨在处理复杂语义、隐蔽注入与上下文关联攻击。构建专门的安全裁决 Prompt，要求 LLM 结合分块的内容，基于深层语义解析，判断是否存在越狱或逻辑陷阱。在模型层面采用“轻量化微调+极致量化+受限解码”的组合策略：选用 1.8B~7B 参数级别的基座模型（如 Qwen 或 Llama）进行指令微调（SFT）；采用 GPTQ 或 AWQ 量化技术将权重压缩至 INT4 格式以降低显存带宽压力；利用受限解码（Constrained Decoding）技术强制模型仅输出预定义的 JSON 结构（如 {"risk": true, "type": "injection"}），避免生成冗长文本，消除生成阶段的耗时瓶颈。

（3）核心机制：中央调度控制器与抢占逻辑

这是本架构的大脑，也是区别于传统方案的创新之处。中央调度控制器（Central Scheduler）作为一个有限状态机（FSM），实时接受来自规则引擎与机器学习层的“结果回报”，并根据回报内容向 LLM 层发送控制信号。其核心逻辑基于“三态抢占机制”。

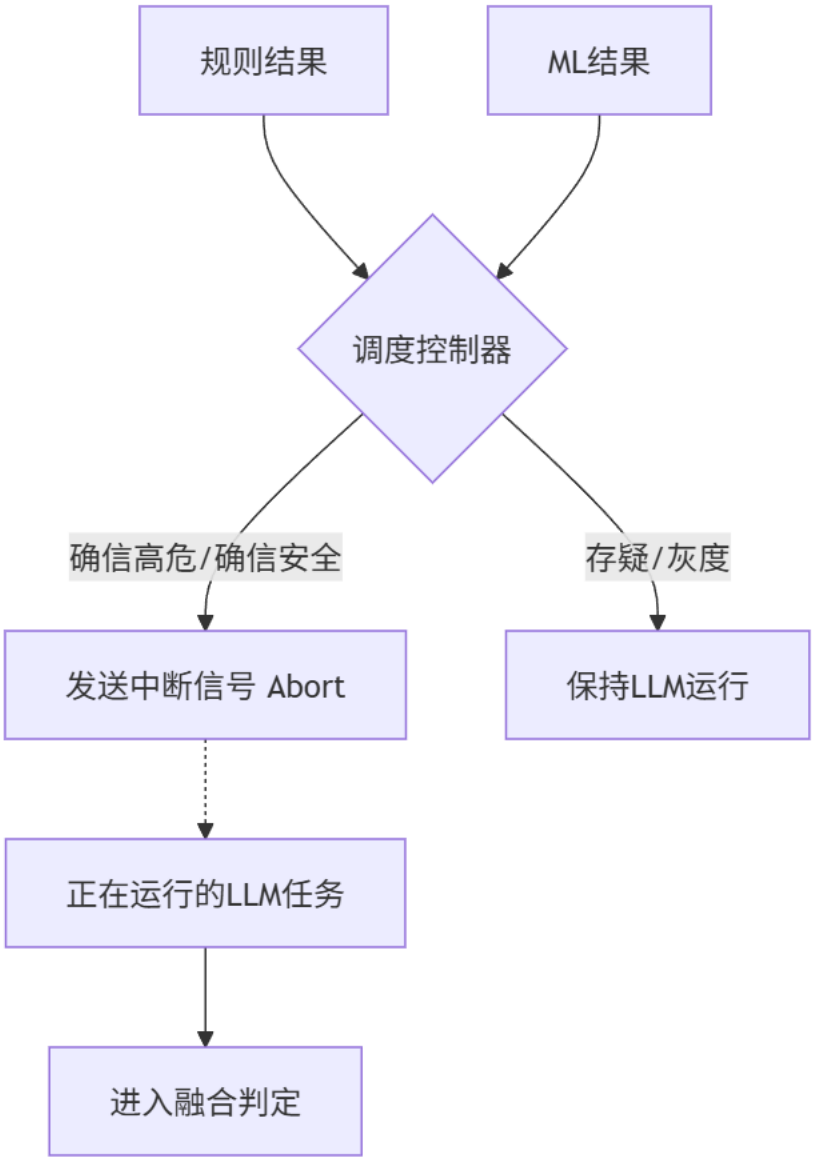

图 1.4　中央调度器示意

对于确信高危（Red Signal）问题，进行立即中断。当规则引擎命中红线，或 ML 模型预测为“高危”且置信度 $P > \theta_{high}$（如 0.95）时，调度器判断已无必要进行 LLM 检测，立即通过 Context Cancel 机制向 LLM 任务发送中断信号，终止 GPU 推理。系统直接输出“拦截”，响应时间取决于 ML 层耗时（约 20ms），大幅节省了 Token 成本。

对于确信安全，进行立即中断。当规则引擎未命中，且 ML 模型预测为“安全”且置信度 $P > \theta_{safe}$（如 0.99）时——针对大量正常的业务闲聊（如“你好”、“查询天气”），调度器同样发送中断信号终止 LLM 任务。系统直接输出“放行”，保证了绝大多数正常请求的低延迟体验。

对于无信号，继续进行任务执行。当规则未命中，且 ML 模型置信度处于中间态（即“存疑”或“灰度”样本）时，调度器保持静默，允许 LLM 任务继续运行直至完成。最终进入融合判定阶段，采用加权投票策略：由于 LLM 在复杂逻辑上具有更高权威性，若 LLM 判定为高危，则覆盖 ML 的存疑结果，执行拦截；若 LLM 判定安全，则放行。

通过上述架构，本研究旨在实现“在 90%的常规流量下具备毫秒级延迟，在 10%的复杂攻击下具备大模型级防御能力”的系统目标。

3.5 可能的创新之处

规则+机器学习+大模型的深度融合：提出多级过滤检测方法，而非简单的串联、并联检测结构；设计合理的调度方法，根据输入文本的特征，选择相对合理的检测路径，确保在面对风险情况下的检测召回率情况。

长文本处理机制：基于滑动窗口的滑动分块机制结合语义连贯性切片机制，确保能够有效的保留长文本的语义情况，实现对于如基于上下文攻击、混合攻击等手段的有效检测。

基于置信度的异步抢占式调度机制：区别于传统的多级串联（逐层过滤）或简单并联（全量计算）架构，本研究创新性地引入了操作系统领域的“抢占式调度”思想。通过建立规则层与机器学习层的“置信度-动作”映射模型，实现了对高耗时大模型任务的动态熔断控制。该机制在数学上证明了可以在不降低安全召回率的前提下，将系统平均响应时间（Average Response Time）逼近轻量级模型的水平，解决了 AI Agent 在实时交互场景下“高安全”与“低延迟”不可兼得的难题。

4 预期达到的目标和研究成果

4.1 预期目标

形成一套针对智能应用长文本输入安全检测的系统性设计理论与方法，同时提供清晰的 API 接口文档，能够实现外部智能体 AI Agent 应用对其的外部调用。

4.2 预期成果

该方法在在应对简单内容合规和内容攻击时，能够以毫秒级的速度快速进行响应；

在面临如上下文的攻击、长文本内容攻击时，同样能够快速进行检测和响应；此外，在检测的结果上，能够保持较高的召回率。

5 论文工作计划

本课题预计在一年左右时间完成，具体的计划如下：

第一阶段（2025.9－2025.12）：完成国内外相关文献的全面梳理与综述撰写；确定整体研究目标，明确研究的方向，同时规划整体技术路线和技术方法，并完成开题报告。

第二阶段（2025.12－2026.4）：基于开源社区或模型，构建相对丰富的训练语料和敏感词库，研究机器学习模型及大模型微调蒸馏等知识，构建核心检测模块；此外，研究长文本结构化表示方式。

第三阶段（2026.4-2026.12）：完成多个模块的整体集成，实现系统原型，通过实验数据集，设计实验，验证有效性，同时完成中期答辩。

第四阶段（2026.6－2027.5）：优化方法设计，并总结研究成果，在导师的指导下完成毕业论文，并准备论文答辩。

参考文献

[1] 任奎, 王志波, 秦湛, 等. 大语言模型越狱攻击与防御[J]. 计算, 2025, 1(7): 55-61.

[2] 薛鋆豪.大语言模型越狱与后门攻防研究[D].杭州电子科技大学,2025.DOI:10.27075/d.cnki.ghzdc.2025.000445.

[3] 生成式人工智能服务管理暂行办法[J].中华人民共和国公安部公报,2023,(05):2-5.

[4]朱家辰.面向生成内容安全的大语言模型攻防技术研究[D].电子科技大学,2025.DOI:10.27005/d.cnki.gdzku.2025.001118.

[5] Wei A, Haghtalab N, Steinhardt J. Jailbroken: How does llm safety training fail?[J]. Advances in Neural Information Processing Systems, 2023, 36: 80079-80110.

[6] 李卓君.面向大语言模型的安全性对齐技术研究[D]. 黑龙江:哈尔滨工业大学,2025.

[7] 欧洲议会与欧盟理事会.人工智能法: Regulation (EU) 2024/1689 of the European Parliament and of the Council of 13 June 2024[Z/OL]. 欧盟官方公报, 2024[2024-06-13].

[8] Bai Y, Jones A, Ndousse K, et al. Training a helpful and harmless assistant with reinforcement learning from human feedback[J]. arXiv preprint arXiv:2204.05862, 2022.

[9] Liu Z, Sun X, Zheng Z. Enhancing llm safety via constrained direct preference optimization[J]. arXiv preprint arXiv:2403.02475, 2024.

[10] 刘会,朱正道,王淞鹤,等.基于深度语义挖掘的大语言模型越狱检测方法研究[J].信息网络安全,2025,25(09):1377-1384.

[11] Kokkula S, Divya G. Palisade--Prompt Injection Detection Framework[J]. arXiv preprint arXiv:2410.21146, 2024.

[12] Rajathi C, Rukmani P. Hybrid Learning Model for intrusion detection system: A combination of parametric and non-parametric classifiers[J]. Alexandria Engineering Journal, 2025, 112: 384-396.

[13] Zhang Z, Lu Y, Ma J, et al. Shieldlm: Empowering llms as aligned, customizable and explainable safety detectors[J]. arXiv preprint arXiv:2402.16444, 2024.

[14] Ghosh S, Varshney P, Galinkin E, et al. Aegis: Online adaptive ai content safety moderation with ensemble of llm experts[J]. arXiv preprint arXiv:2404.05993, 2024.

[15] Liu Y, Jia Y, Jia J, et al. DataSentinel: A Game-Theoretic Detection of Prompt Injection Attacks[C]//2025 IEEE Symposium on Security and Privacy (SP). IEEE, 2025: 2190-2208.

[16] Greshake K, Abdelnabi S, Mishra S, et al. Not what you've signed up for: Compromising real-world llm-integrated applications with indirect prompt injection[C]//Proceedings of the 16th ACM workshop on artificial intelligence and security. 2023: 79-90.

[17] ZHONG P Y, CHEN S, WANG R, et al. Rtbas: defending llm agents against prompt injection and privacy leakage[J/OL]. arXiv, 2025[2025-02-12].

[18] 刘会,朱正道,王淞鹤,等.基于深度语义挖掘的大语言模型越狱检测方法研究[J].信息网络安全,2025,25(09):1377-1384.

[19] 沈晓晨, 葛寅辉, 陈波, 等. 人工智能安全知识图谱构建技术研究[J]. Chinese Journal of Network & Information Security, 2023, 9(2).

[20] 夏鸿斌, 肖奕飞, 刘渊. 融合自注意力机制的长文本生成对抗网络模型[J]. Journal of Frontiers of Computer Science & Technology, 2022, 16(7).

[21] 牛犇, 李铂浩, 唐鹏, 等. 基于文本自动化分类的隐私政策合规技术研究[J]. 信息安全学报.